

RELATÓRIO FINAL – Breast Cancer Wisconsin (Diagnostic)

Bianca Couto Araujo

1. Propósito do Dataset e Identificação do Atributo Target

O dataset **Breast Cancer Wisconsin (Diagnostic)** reúne informações de exames de imagem digitalizados (biópsias de mama) contendo medidas numéricas derivadas das características das células tumorais, como textura, concavidade, uniformidade, área, raio, simetria, entre outras.

Essas medições são computadas a partir de imagens digitalizadas de massa mamária e representam aspectos importantes do comportamento celular.

Possibilidade de Uso para Predição

Os dados podem ser utilizados para diversas tarefas preditivas, como:

- Classificação de tumores em malignos ou benignos
- Identificação de padrões de risco
- Apoio ao diagnóstico clínico automatizado
- Triagem inicial antes de avaliação médica
- Apoio em pesquisas de oncologia computacional

Identificação do Atributo Classe (Target)

O atributo target do dataset é:

- **target**
 - Valor **0** - tumor **maligno**
 - Valor **1** - tumor **benigno**

Este é o atributo que foi utilizado para todos os experimentos de predição de classificação neste trabalho.

2. Caracterização e Exploração do Dataset

2.1 Quantidade de Instâncias

- 569 instâncias (exemplos/pacientes analisados)

2.2 Quantidade de Atributos

- 30 atributos numéricos referentes às medições das células
- 1 atributo target binário
- Total: 31 colunas

2.3 Tipos de Atributos

Todos os atributos (exceto o target) são numéricos contínuos.

O target é numérico discreto (binário).

2.4 Intervalo ou Conjunto de Valores dos Atributos

Os atributos possuem escalas diversas. Exemplos típicos:

2.5 Atributos com Valores Faltantes

- Nenhum atributo possui missing values.

2.6 Atributo Mais Desbalanceado


O dataset possui leve desbalanceamento no atributo target:

- 357 benignos (63%)
- 212 malignos (37%)


O mais desbalanceado, portanto, é o target, classe benigna predominante.

2.7 Gráficos Explorados


- Distribuição do target



- Histogramas dos atributos



- Matriz de correlação



3. Pré-processamento dos Dados

O dataset Breast Cancer Wisconsin (Diagnostic) não possui valores faltantes, porém, para garantir um pipeline mais robusto e compatível com diferentes algoritmos, foi incluída uma etapa de imputação utilizando a estratégia mean dentro do pipeline de pré-processamento. Dessa forma, caso o dataset seja reutilizado ou ampliado, o fluxo continua funcional sem necessidade de ajustes.

Em seguida, foi aplicada a técnica de padronização (StandardScaler) em todos os atributos numéricos. Esse procedimento centraliza os dados na média e os escala para desvio padrão igual a 1, o que melhora o desempenho de algoritmos sensíveis à escala, como Regressão Logística e Gradient Boosting.

O conjunto de dados foi dividido em 70% para treino e 30% para teste, utilizando divisão estratificada para preservar a proporção entre as classes (benigno e maligno). Essa prática é essencial quando há desbalanceamento, mesmo que leve, como neste dataset.

Não houve necessidade de transformar o atributo classe, pois o target já se encontra no formato numérico binário adequado (0 = maligno, 1 = benigno). Da mesma forma, não foi necessário criar versões alternativas do dataset ou aplicar técnicas de redução/ampliação de instâncias, pois o tamanho e a estrutura do dataset são adequados para os algoritmos utilizados.

4. Análise dos Três Algoritmos de Aprendizado de Máquina

Foram testados três modelos:

1. **Logistic Regression**
2. **Random Forest**
3. **Gradient Boosting**

Todos foram avaliados com:

- Acurácia
- Precisão Macro
- Recall Macro
- F1-score Macro
- Tempo de treinamento
- Tempo de predição

Tabela de Resultados Reais

Modelo	Acurácia	Precisão	Recall	F1	Tempo Treino (s)	Tempo Predição (s)
Logistic Regression	0.9883	0.9875	0.9875	0.9875	7.03	6.28

Random Forest	0.9415	0.9402	0.934	0.937	4.48	19.74
			4	1		
Gradient Boosting	0.9532	0.9563	0.943	0.949	12.01	4.53
			7	3		

5. Comparação dos Algoritmos

5.1 Melhor Desempenho Geral

O **Logistic Regression** apresentou o melhor desempenho em todas as métricas:

- **Acurácia:** 0.9883
- **Precisão Macro:** 0.9875
- **Recall Macro:** 0.9875
- **F1-score Macro:** 0.9875

O modelo conseguiu identificar ambas as classes com excelente desempenho, mesmo com leve desbalanceamento.

5.2 Pior Desempenho Geral

O **Random Forest** apresentou a menor performance nas métricas:

- **Acurácia:** 0.9415
- **F1:** 0.9371
- **Recall Macro:** 0.9344

Apesar de ainda ser um bom resultado, ficou abaixo dos demais.

5.3 Análise Classe por Classe

Como o dataset é binário:

- **Classe 1 (benigno)** costuma ter métricas **mais altas**, por ser majoritária

- **Classe 0 (maligno)** tende a ter recall ligeiramente mais baixo nos modelos piores (Random Forest), pois é a classe minoritária

No melhor modelo (**Logistic Regression**), ambas as classes possuem desempenho praticamente idêntico, indicando:

- Excelente separabilidade dos dados
- Pouquíssimo overfitting
- Modelo robusto para aplicação médica

6. Tempo de Treinamento e Predição

Treinamento

- Mais rápido - **Random Forest (4.48s)**
- Mais lento - **Gradient Boosting (12.01s)**

Predição

- Mais rápido - **Gradient Boosting (4.53s)**
- Mais lento - **Random Forest (19.74s)**

7. Conclusão

O dataset Breast Cancer Wisconsin permite a criação de modelos altamente eficazes para **predição de tumores malignos ou benignos**, desempenhando um papel relevante no apoio ao diagnóstico médico.

Entre os modelos avaliados:

- **Melhor desempenho geral:** *Logistic Regression*
- **Pior desempenho geral:** *Random Forest*
- **Melhor desempenho por classe:** Classe **benigna**
- **Classe mais difícil:** Tumores **malignos** (classe minoritária)

Mesmo assim, os três modelos apresentaram métricas elevadas, refletindo que o dataset possui ótimo sinal para classificação.

Os resultados obtidos neste trabalho são consistentes com as análises apresentadas na documentação e nos exemplos de referência da Scikit-learn, que também indicam desempenho elevado para modelos lineares e baseados em gradiente neste dataset. Dessa forma, os resultados encontrados confirmam o padrão esperado para o Breast Cancer Wisconsin (Diagnostic), reforçando a confiabilidade dos modelos avaliados.

7. Repositório do Projeto

Após a finalização da implementação, os notebooks, scripts, modelos treinados, gráficos, tabelas e o arquivo original do dataset foram organizados e publicados no GitHub para referência e reprodutibilidade dos experimentos.

Repositório do projeto: https://github.com/bbicouto/projeto_breast_cancer.git